

Apprentissage Statistique en Grande Dimension- Examen

Le barème est approximatif. On veillera à justifier les réponses avec soin.

- Exercice 1** (6,5pts). 1. (0,5pt) Supposons que vous utilisiez un arbre de décision qui a tendance à surajuster l'erreur d'entraînement. Comment faut-il modifier le paramètre `max_depth`? Réponse : Il faut réduire ce paramètre de profondeur pour réduire le potentiel surapprentissage.
2. (0,75pt) Est-il important de normaliser des données avant d'utiliser un arbre de décision? Réponse : D'abord, notons que la question de la normalisation n'a du sens que pour les variables quantitatives. Supposons donc pour simplifier que les variables d'entrée sont toutes quantitatives. L'arbre est alors une règle de partitionnement basée sur des coupures de la forme $X_i \leq a$ contre $X_i > a$, la normalisation ne modifiera pas les variables sélectionnées et les valeurs des seuils subiront simplement une homothétie.
3. (0,75pt) Quel est la différence principale entre le bagging d'arbres de décision et les forêts aléatoires? Quel est l'effet recherché par cette modification? Réponse : Dans les forêts aléatoires, un sous-ensemble de variables est tiré au sort à chaque noeud. Cela permet (potentiellement) de réduire la corrélation entre les arbres en évitant que les coupures soient systématiquement faites avec les mêmes variables.
4. (0,5pt) Quel est l'effet recherché par l'utilisation de la validation croisée vis-à-vis de la validation simple? Réponse : La validation croisée a pour but de réduire le biais d'apprentissage, plus précisément, de réduire la dépendance de l'erreur de validation à l'échantillon d'apprentissage que l'on a tiré au sort.
5. (1 pt) Supposons que vous utilisiez une régression ridge. Vous remarquez que l'erreur d'entraînement et l'erreur de validation sont à peu près identiques et assez élevées. Faut-il augmenter ou diminuer l'hyperparamètre de pénalisation λ ? Précisez si vous cherchez à réduire le biais ou la variance (en justifiant). Réponse : Dans ce cas, on peut estimer qu'il n'y a pas de surapprentissage puisque l'erreur de validation n'est pas plus grande que l'erreur d'entraînement. On peut donc tenter au contraire de réduire la valeur de λ afin de donner plus de flexibilité au modèle et donc de réduire le biais.
6. (2,5pts) Quelle méthode inspirée des techniques de pénalisation vues en cours pour réduire le nombre de connexions dans un réseau de neurones? Expliquez sur l'exemple de la classification multiclassées les modifications à effectuer sur le réseau de neurones (en précisant la fonction à minimiser)? Quels problèmes théoriques (et numériques) cela engendre-t-il? Réponse : On peut utiliser une pénalisation L^1 des paramètres $\omega_{i,j}^{(\ell)}$ de connexions entre les neurones. Dans le cadre de la classification multiclassées, on utilise une régression softmax avec le plus classiquement, l'entropie croisée comme fonction de perte. En notant simplement F_θ la fonction à valeurs dans $\mathbb{R}^K$ à la sortie du réseau de neurones avant application de la fonction softmax, le nouveau problème consisterait à minimiser

$$L_N(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \mathbf{1}_{Y_i=k} \log(\pi_k^{F_\theta}(X_i)) + \lambda \|\theta\|_1$$

avec

$$\pi_k^F(x) = \frac{e^{F_\theta^k(x)}}{\sum e^{F_\theta^\ell(x)}}.$$

Comme la méthode d'optimisation est basée sur une descente de gradient (stochastique), on a ici un problème de différentiabilité qui pose un problème théorique et qui peut poser un problème numérique. Notons néanmoins que les fonctions d'activation **Relu** ont le même problème et que l'on ne s'en soucie guère (en tout cas à l'heure actuelle!) dans l'utilisation de la descente de gradient...

Exercice 2. (4pts+1,5 Bonus) On note (X, Y) un couple de variables aléatoires telles que $X \in \mathcal{X}$ et $Y \in \{0, 1\}$. On note $\eta(X) = \mathbb{P}(Y = 1|X)$. Soit $\omega = (\omega_0, \omega_1)$ où ω_0 et ω_1 sont dans $\mathbb{R}_+^*$. On considère le risque de classification pondéré défini pour une fonction $f : \mathcal{X} \rightarrow 0, 1$ par

$$R_\omega(f) = \omega_0 \mathbb{P}(Y = 0, f(X) = 1) + \omega_1 \mathbb{P}(Y = 1, f(X) = 0).$$

1. (2pts) Montrez avec soin que la fonction f^* définie par

$$f^*(x) = \mathbf{1}_{\{\eta(x) > \frac{\omega_0}{\omega_0 + \omega_1}\}}, \quad x \in \mathcal{X}$$

est la règle de Bayes associée à ce problème.

Réponse : En conditionnant par rapport à X , on a :

$$\mathbb{P}(Y = 0, f(X) = 1) = \mathbb{E}[\mathbb{E}[1_{Y=0}|X]1_{f(X)=1}] = \mathbb{E}[(1 - \eta(X))1_{f(X)=1}].$$

De même, $\mathbb{P}(Y = 1, f(X) = 0) = \mathbb{E}[\eta(X)1_{f(X)=0}]$. Il vient

$$R_\omega(f) = \mathbb{E}[\omega_0(1 - \eta(X))1_{f(X)=1} + \omega_1\eta(X)1_{f(X)=0}].$$

Ainsi, comme pour tout $x \in \mathcal{X}$,

$$\omega_0(1 - \eta(x))1_{f(x)=1} + \omega_1\eta(x)1_{f(x)=0} \geq \min(\omega_0(1 - \eta(x)), \omega_1\eta(x)),$$

on en déduit que

$$R_\omega(f) \geq \mathbb{E}[\min(\omega_0(1 - \eta(X)), \omega_1\eta(X))].$$

On remarque maintenant que

$$\omega_0(1 - \eta(x)) \leq \omega_1\eta(x) \iff \eta(x) \geq \frac{\omega_0}{\omega_0 + \omega_1}.$$

Ainsi, il est clair que la fonction f^* proposée satisfait

$$f^*(x) = 1 \iff \eta(x) > \frac{\omega_0}{\omega_0 + \omega_1} \iff \omega_0(1 - \eta(x)) = \min(\omega_0(1 - \eta(x)), \omega_1\eta(x)),$$

puis

$$R_{f^*} = \mathbb{E}[\min(\omega_0(1 - \eta(X)), \omega_1\eta(X))].$$

f^* est donc la règle de Bayes associée au problème.

2. (1,5pt) On note $\mathcal{D}_n$ un échantillon d'apprentissage et $\hat{f}$ un prédicteur (une fonction de l'échantillon d'apprentissage). On rappelle que si (X, Y) est indépendant de $\mathcal{D}_n$,

$$R_\omega(\hat{f}) = \omega_0 \mathbb{P}(Y = 0, \hat{f}(X) = 1|\mathcal{D}_n) + \omega_1 \mathbb{P}(Y = 1, \hat{f}(X) = 0|\mathcal{D}_n).$$

Montrez que

$$\mathbb{E}[R_\omega(\hat{f})] - R_\omega(f^*) = \mathbb{E}[\omega_1\eta(X) - \omega_0(1 - \eta(X))\mathbf{1}_{\hat{f}(X) \neq f^*(X)}].$$

Réponse : Comme (X, Y) est indépendant de $\mathcal{D}_n$, on a :

$$\mathbb{P}(Y = 0, \hat{f}(X) = 1 | \mathcal{D}_n, X) = \phi(\hat{f})$$

où

$$\phi(f) = \mathbb{P}(Y = 0, f(X) = 1 | X) = (1 - \eta(X))1_{f(X)=1}.$$

En procédant de la même manière pour le second terme, on en déduit que

$$\begin{aligned} \mathbb{E}[R_\omega(\hat{f})] &= \omega_0 \mathbb{E}[\mathbb{P}(Y = 0, \hat{f}(X) = 1 | \mathcal{D}_n)] + \omega_1 \mathbb{E}[\mathbb{P}(Y = 1, f(X) = 0 | \mathcal{D}_n)] \\ &= \mathbb{E}[\omega_0(1 - \eta(X))1_{\hat{f}(X)=1} + \omega_1\eta(X)1_{\hat{f}(X)=0}], \end{aligned}$$

puis que

$$\begin{aligned} \mathbb{E}[R_\omega(\hat{f})] - R_\omega(f^*) &= \mathbb{E}[\omega_0(1 - \eta(X)) (1_{\hat{f}(X)=1} - 1_{f^*(X)=1}) + \omega_1\eta(X) (1_{\hat{f}(X)=0} - 1_{f^*(X)=0})] \\ &= \mathbb{E}[(\omega_0(1 - \eta(X)) - \omega_1\eta(X)) (1_{\hat{f}(X)=1, f^*(X)=0})] \\ &\quad - \mathbb{E}[(\omega_0(1 - \eta(X)) - \omega_1\eta(X)) (1_{\hat{f}(X)=0, f^*(X)=1})]. \end{aligned}$$

D'après la question précédente, $f^*(x) = 0$ si et seulement si $\omega_0(1 - \eta(x)) - \omega_1\eta(x) \geq 0$ ce qui permet de conclure.

3. (2pts dont 1,5 Bonus) On suppose dans cette question que

$$\hat{f}(x) = \mathbf{1}_{\{\hat{\eta}(X) > \frac{\omega_0}{\omega_0 + \omega_1}\}}$$

avec $\hat{\eta}$ un estimateur de η . A l'aide de la question précédente, montrez que

$$0 \leq \mathbb{E}[R_\omega(\hat{f})] - R_\omega(f^*) \leq (\omega_0 + \omega_1) \mathbb{E}[|\hat{\eta}(X) - \eta(X)|].$$

Indication : On pourra minorer $|\hat{\eta}(x) - \eta(x)|$ lorsque $\hat{f}(x) \neq f^(x)$.*

Réponse : Le fait que la quantité soit positive est clair puisqu'il s'agit de l'espérance d'une fonction positive (par ailleurs, cela se déduit directement du fait que f^* est la règle de Bayes). Pour montrer l'autre inégalité, on commence par remarquer que si $\hat{f}(x) = 1$ et $f^*(x) = 0$, alors $\eta(x) \leq \frac{\omega_0}{\omega_0 + \omega_1}$ et $\hat{\eta}(x) > \frac{\omega_0}{\omega_0 + \omega_1}$ de sorte que

$$|\hat{\eta}(x) - \eta(x)| = \hat{\eta}(x) - \eta(x) \geq \frac{\omega_0}{\omega_0 + \omega_1} - \eta(x) = |\eta(x) - \frac{\omega_0}{\omega_0 + \omega_1}|.$$

A l'inverse, si $\hat{f}(x) = 0$ et $f^*(x) = 1$,

$$|\hat{\eta}(x) - \eta(x)| = \eta(x) - \hat{\eta}(x) \geq \eta(x) - \frac{\omega_0}{\omega_0 + \omega_1} = |\eta(x) - \frac{\omega_0}{\omega_0 + \omega_1}|.$$

Ainsi, pour tout $x \in \mathcal{X}$,

$$|\hat{\eta}(x) - \eta(x)| \geq |\eta(x) - \frac{\omega_0}{\omega_0 + \omega_1}|.$$

Or, en remarquant que

$$|\omega_0(1 - \eta(X)) - \omega_1\eta(X)| = (\omega_0 + \omega_1) |\eta(X) - \frac{\omega_0}{\omega_0 + \omega_1}|,$$

on déduit

$$\begin{aligned} \mathbb{E}[R_\omega(\hat{f})] - R_\omega(f^*) &= (\omega_0 + \omega_1) \mathbb{E}[|\eta(X) - \frac{\omega_0}{\omega_0 + \omega_1}| \mathbf{1}_{\hat{f}(X) \neq f^*(X)}] \\ &\leq (\omega_0 + \omega_1) \mathbb{E}[|\hat{\eta}(X) - \eta(X)| \mathbf{1}_{\hat{f}(X) \neq f^*(X)}] \end{aligned}$$

puis le résultat.

Exercice 3 (4,5pts). Soit $p \geq 2$. On note $\mathcal{F} = \{f_\theta, \theta \in \Theta\}$ un ensemble de fonctions de $\mathbb{R}^p$ dans $\{-1, 1\}$. Cet ensemble $\mathcal{F}$ est appelé modèle de classification (binaire). On dit que $\mathcal{F}$ *pulvérise* $(x_1, \dots, x_n)$, un ensemble de points de $\mathbb{R}^p$ si quels que soient les labels des x_i (-1 ou 1), il existe une fonction de l'ensemble $\mathcal{F}$ qui classe parfaitement les données. On suppose dans la suite que les x_i sont des réalisations de variables aléatoires X_i indépendantes de loi uniforme sur $[0, 1]^p$ et on note

$$n^{VC} = \sup\{n \in \mathbb{N}^*, p.s. \quad \mathcal{F} \text{ pulvérise } (X_1, \dots, X_n)\}.$$

1. (1,5 pt) Montrez que si

$$\mathcal{F} = \{f : \mathbb{R}^p \rightarrow \{-1, 1\}, f(x) = \text{sgn}(\langle w, x \rangle + b), w \in \mathbb{R}^p, b \in \mathbb{R}\},$$

alors $n^{VC} = 3$ (on pourra illustrer par des dessins ; en particulier, pour montrer que n^{VC} ne peut être égal à 4, on pourra se contenter de dessiner un ensemble de 4 points labellisés $+$ ou $-$ ne pouvant être pulvérisés en dimension 2).

Réponse : D'abord, *p.s.* les 3 points ne sont pas alignés. Ainsi, en dimension 2, lorsque l'on a 3 points, ces 3 points forment *p.s.* un triangle ABC . Si on suppose que A et B ont la même étiquette, alors la droite passant par les milieux de AC et BC pulvérise les points A , B et C . En effet, si l'on suppose que cette droite a comme équation $\langle w, x \rangle + b = 0$, il suffit alors de considérer le prédicteur $f(x) = \text{sgn}(\langle w, x \rangle + b)$ ou $f(x) = \text{sgn}(\langle -w, x \rangle - b)$ (en fonction de l'étiquette de A et B). En dimension supérieure, le raisonnement est similaire en prenant un hyperplan orthogonal au plan formé par A , B et C et passant par les milieux de AC et BC . Comme ce raisonnement fonctionne quelles que soient les étiquettes choisies pour chacun des points (car dans tous les cas, 2 des 3 points ont la même étiquette), on en déduit que $n^{VC} \geq 3$. Avec 4 points : notons C_1, C_2, C_3 et C_4 les carrés ouverts $]0, 1/2[\times]0, 1/2[,]0, 1/2[\times]1/2, 1[,]1/2, 1[\times]0, 1/2[,$ et $]1/2, 1[\times]1/2, 1[$. Si l'on suppose que $x_i \in C_i$ avec les étiquettes $1, -1, -1, 1$ (respectivement), on constate facilement qu'aucune droite ne peut séparer parfaitement les points. Comme

$$\mathbb{P}(X_i \in C_i, i = 1 \dots, 4) > 0,$$

on en déduit le résultat.

2. (1,5pt) On suppose que $p = 2$ et on note $\mathcal{F}$ l'ensemble des règles de décision associées à un arbre binaire de profondeur inférieure ou égale à 2. Expliquez pourquoi $n^{VC} = 4$ (même type d'argumentaire que dans la question précédente).

Réponse : On fait d'abord une coupe verticale permettant de conserver deux points d'un côté puis deux points de l'autre. On fait ensuite deux coupes horizontales pour séparer chacun des deux points. Le classifieur associé est trivialement parfait puisque chaque feuille est formée d'un seul élément. Par contre, avec 5 points, ça ne fonctionne plus en toute généralité. Notons $x_i = (a_i, b_i)$ et supposons que $a_1 < a_2 \dots < a_5$ et que $b_1 < \dots < b_5$ et que les étiquettes sont alternées : $1, -1, 1, -1, 1$. Quelle que soit la première coupe, il reste au moins 3 points d'un côté avec les deux étiquettes représentées. Tel qu'est construit le jeu de données, on a forcément l'étiquette différente "au milieu" des deux autres et il n'est alors pas possible de séparer les points parfaitement. On en conclut que $n_{VC} = 4$.

3. (1pt) A votre avis, avec quel type de notion usuelle d'apprentissage statistique la quantité n^{VC} est-elle associée ? Quelle indication peut alors donner cette quantité sur la ... du modèle ?

Réponse : Cette quantité n^{VC} est reliée à la flexibilité du modèle. Plus n^{VC} est grand, plus le modèle est flexible.

Exercice 4 (6pts). On considère un échantillon d'apprentissage $\{(x_i, y_i), i = 1, \dots, n\}$ où x_i est dans $\mathbb{R}^p$ et $y_i \in \mathbb{R}$. Soit $\varepsilon > 0$. On considère le problème d'optimisation suivant :

$$\begin{cases} \min_{\beta, \beta_0} \frac{1}{2} \|\beta\|_2^2 & \text{sous les contraintes} \\ y_i - (\langle \beta, x_i \rangle + \beta_0) \leq \varepsilon & \text{et } \langle \beta, x_i \rangle + \beta_0 - y_i \leq \varepsilon \quad \forall i \in \{1, \dots, n\}. \end{cases}$$

- (1 pt) Quelle interprétation pouvez-vous donner de ce problème d'optimisation ? De quel algorithme de régression vu en cours se rapproche-t-il ? Expliquez votre réponse.

Réponse : Dans la famille des fonctions f de $\mathbb{R}^p \rightarrow \mathbb{R}$ de la forme $f(x) = \langle \beta, x \rangle + \beta_0$ et telles que pour tous les points de l'échantillon

$$|f(x_i) - y_i| \leq \varepsilon,$$

on cherche celle dont la norme euclidienne de β est minimale (dans la littérature, on parle de recherche de “flatness”). Ce problème ressemble beaucoup à la régression Ridge à la différence près que l'on remplace l'erreur des moindres carrés par une contrainte de type “tube”.

- (0,5pt) Comment modifier ce problème pour que la contrainte puisse être flexible ?

Réponse : En procédant de manière similaire au classifieur SVM (en fait, il s'agit ici d'une formulation du problème pour les SVR), on peut remplacer la contrainte de tube non flexible par une contrainte flexible en cherchant

$$\begin{cases} \min_{\beta, \beta_0} \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i & \text{sous les contraintes} \\ y_i - (\langle \beta, x_i \rangle + \beta_0) \leq \varepsilon + \xi_i & \text{et } \langle \beta, x_i \rangle + \beta_0 - y_i \leq \varepsilon + \xi_i \quad \forall i \in \{1, \dots, n\}. \end{cases}$$

Bien entendu, même si ça n'est pas clairement demandé dans la question, on pénalise la flexibilité pour que le problème garde du sens.

- (1 pt) Ecrire le lagrangien $L(\beta, \beta_0, \alpha, \alpha^*)$ associé à ce problème à l'aide de coefficients $\alpha_i, \alpha_i^*, i = 1, \dots, n$ (On écrira les deux contraintes sous la forme $\geq$).

Réponse : Le Lagrangien associé à ce problème peut s'écrire :

$$L(\beta, \beta_0, \alpha, \alpha^*) = \frac{1}{2} \|\beta\|_2^2 - \sum_{i=1}^n \alpha_i (\varepsilon + \langle \beta, x_i \rangle + \beta_0 - y_i) - \sum_{i=1}^n \alpha_i^* (\varepsilon + y_i - \langle \beta, x_i \rangle - \beta_0).$$

- (1pt) Ecrire les équations de stationnarité associées. En notant $(\beta(\alpha), \beta_0(\alpha))$ une solution du problème, en déduire une expression de $\beta(\alpha)$ en fonction des α_i, α_i^* et x_i .

Réponse : On résout

$$\begin{cases} \frac{\partial L}{\partial \beta} = 0 \\ \frac{\partial L}{\partial \beta_0} = 0 \end{cases} \iff \begin{cases} \beta - \sum_{i=1}^n \alpha_i x_i + \sum_{i=1}^n \alpha_i^* x_i = 0 \\ -\sum_{i=1}^n \alpha_i + \sum_{i=1}^n \alpha_i^* = 0 \end{cases} \iff \begin{cases} \beta = \sum_{i=1}^n (\alpha_i - \alpha_i^*) x_i, \\ \sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0. \end{cases}$$

- (1pt) En déduire une expression simplifiée de $L(\beta(\alpha), \beta_0(\alpha), \alpha, \alpha^*)$ ainsi que le nouveau problème d'optimisation à résoudre (on n'oubliera pas la contrainte).

Réponse : En réinjectant les solutions des équations de stationnarité, on trouve d'abord que

$$L(\beta, \beta_0, \alpha, \alpha^*) = \frac{1}{2} \left\| \sum_{i=1}^n (\alpha_i - \alpha_i^*) x_i \right\|_2^2 - \sum_{i=1}^n \alpha_i \left(\left\langle \sum_{j=1}^n (\alpha_j - \alpha_j^*) x_j, x_i \right\rangle - y_i \right) - \sum_{i=1}^n \alpha_i^* \left(y_i - \left\langle \sum_{j=1}^n (\alpha_j - \alpha_j^*) x_j, x_i \right\rangle \right).$$

En développant, il vient

$$\tilde{L}(\alpha, \alpha^*) = -\frac{1}{2} \sum_{i,j} (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) x_i x_j - \sum_i (\alpha_i - \alpha_i^*) y_i.$$

Ainsi, le problème d'optimisation dual consiste à maximiser en α, α^* la fonction $\tilde{L}$ sous la contrainte $\sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0$. Finalement, cela revient de manière équivalente au problème suivant : déterminer

$$\begin{cases} \min_{\alpha, \alpha^*} \frac{1}{2} \sum_{i,j} (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) x_i x_j - \sum_i (\alpha_i - \alpha_i^*) y_i \\ \text{sous la contrainte} \quad \sum_i (\alpha_i - \alpha_i^*) = 0. \end{cases}$$

6. (1pt) Supposons les α_i, α_i^* calculés. Quelle est l'expression du prédicteur f obtenu en fonction des α_i, α_i^* et β_0 ?

Réponse : Le prédicteur s'écrit simplement

$$\hat{f}(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \langle x_i, x \rangle + \beta_0.$$

7. (0,5pt) Comment retrouver l'expression de β_0 ?

Réponse : On s'appuie sur les vecteurs supports. Plus précisément, il existe au moins un indice i_1 tel que α_{i_1} est strictement positif et donc (d'après les conditions KKT),

$$y_{i_1} + (\langle \beta, x_{i_1} \rangle + \beta_0) = \varepsilon.$$

On en déduit donc que

$$\beta_0 = \varepsilon - y_1 - \sum_{i=1}^n \langle (\alpha_i - \alpha_i^*) x_i, x_{i_1} \rangle.$$

N.B. On peut aussi trouver d'autres expressions en prenant deux indices i_1 et i_2 tels que α_{i_1} et $\alpha_{i_2}^*$ strictement positifs.