

Apprentissage Statistique en Grande Dimension- Examen

Le barème est approximatif. On veillera à justifier les réponses avec soin.

- Exercice 1** (6pts). 1. (0,5pt) Supposons que vous utilisiez un arbre de décision qui a tendance à surajuster l'erreur d'entraînement. Comment faut-il modifier le paramètre `max_depth` ?
2. (1pt) Est-il important de normaliser des données avant d'utiliser un arbre de décision ?
3. (1pt) Quel est la différence principale entre le bagging d'arbres de décision et les forêts aléatoires ? Quel est l'effet recherché par cette modification ?
4. (0,5pt) Quel est l'effet recherché par l'utilisation de la validation croisée vis-à-vis de la validation simple ?
5. (1 pt) Supposons que vous utilisiez une régression ridge. Vous remarquez que l'erreur d'entraînement et l'erreur de validation sont à peu près identiques et assez élevées. Faut-il augmenter ou diminuer l'hyperparamètre de pénalisation λ ? Précisez si vous cherchez à réduire le biais ou la variance (en justifiant).
6. (2,5pts) Quelle technique de pénalisation vue en cours et alternative au dropout pourriez-vous utiliser pour réduire le nombre de connexions dans un réseau de neurones ? Expliquez sur l'exemple de la classification multiclass les modifications à effectuer sur le réseau de neurones (en précisant la fonction à minimiser) ? Quels problèmes théoriques (et numériques) cela engendre-t-il ? Cela est-il un problème nouveau dans le cadre des réseaux de neurones ?

Exercice 2. (4pts+1,5 Bonus) On note (X, Y) un couple de variables aléatoires telles que $X \in \mathcal{X}$ et $Y \in \{0, 1\}$. On note $\eta(X) = \mathbb{P}(Y = 1|X)$. Soit $\omega = (\omega_0, \omega_1)$ où ω_0 et ω_1 sont dans $\mathbb{R}_+^*$. On considère le risque de classification pondéré défini pour une fonction $f : \mathcal{X} \rightarrow 0, 1$ par

$$R_\omega(f) = \omega_0 \mathbb{P}(Y = 0, f(X) = 1) + \omega_1 \mathbb{P}(Y = 1, f(X) = 0).$$

1. (2pts) Montrez avec soin que la fonction f^* définie par

$$f^*(x) = \mathbf{1}_{\{\eta(x) > \frac{\omega_0}{\omega_0 + \omega_1}\}}, \quad x \in \mathcal{X}$$

est la règle de Bayes associée à ce problème.

2. (1,5pt) On note $\mathcal{D}_n$ un échantillon d'apprentissage et $\hat{f}$ un prédicteur (une fonction de l'échantillon d'apprentissage). On rappelle que si (X, Y) est indépendant de $\mathcal{D}_n$,

$$R_\omega(\hat{f}) = \omega_0 \mathbb{P}(Y = 0, \hat{f}(X) = 1 | \mathcal{D}_n) + \omega_1 \mathbb{P}(Y = 1, \hat{f}(X) = 0 | \mathcal{D}_n).$$

Montrez que

$$\mathbb{E}[R_\omega(\hat{f})] - R_\omega(f^*) = \mathbb{E}[|\omega_1 \eta(X) - \omega_0(1 - \eta(X))| \mathbf{1}_{\hat{f}(X) \neq f^*(X)}].$$

3. (2pts dont 1,5 Bonus) On suppose dans cette question que

$$\hat{f}(x) = \mathbf{1}_{\{\hat{\eta}(x) > \frac{\omega_0}{\omega_0 + \omega_1}\}}$$

avec $\hat{\eta}$ un estimateur de η . A l'aide de la question précédente, montrez que

$$0 \leq \mathbb{E}[R_\omega(\hat{f})] - R_\omega(f^*) \leq (\omega_0 + \omega_1) \mathbb{E}[|\hat{\eta}(X) - \eta(X)|].$$

Indication : On pourra minorer $|\hat{\eta}(x) - \eta(x)|$ lorsque $\hat{f}(x) \neq f^(x)$.*

Exercice 3 (4,5pts). On note $\mathcal{F} = \{f_\theta, \theta \in \Theta\}$ un ensemble de fonctions de $\mathbb{R}^p$ dans $\{-1, 1\}$. Cet ensemble $\mathcal{F}$ est appelé modèle de classification (binaire). On dit que $\mathcal{F}$ *pulvérise* $(x_1, \dots, x_n)$, un ensemble de points de $\mathbb{R}^p$ si quels que soient les labels des x_i (-1 ou 1), il existe une fonction de l'ensemble $\mathcal{F}$ qui classe parfaitement les données. On suppose dans la suite que les x_i sont des réalisations de variables aléatoires X_i indépendantes de loi uniforme sur $[0, 1]^p$ et on note

$$n^{VC} = \sup\{n \in \mathbb{N}^*, p.s. \quad \mathcal{F} \text{ pulvérise } (X_1, \dots, X_n)\}.$$

1. (1,5 pt) Montrez que si

$$\mathcal{F} = \{f : \mathbb{R}^p \rightarrow \{-1, 1\}, f(x) = \text{sgn}(\langle w, x \rangle + b), w \in \mathbb{R}^p, b \in \mathbb{R}\},$$

alors $n^{VC} = 3$ (on pourra illustrer par des dessins ; en particulier, pour montrer que n^{VC} ne peut être égal à 4, on pourra se contenter de dessiner un ensemble de 4 points labellisés $+$ ou $-$ ne pouvant être pulvérisés en dimension 2).

2. (1,5pt) On suppose que $p = 2$ et on note $\mathcal{F}$ l'ensemble des règles de décision associées à un arbre binaire de profondeur inférieure ou égale à 2. Expliquez pourquoi $n^{VC} = 4$ (même type d'argumentaire que dans la question précédente).
3. (1pt) A votre avis, avec quel type de notion usuelle d'apprentissage statistique la quantité n^{VC} est-elle associée ? Quelle indication peut alors donner cette quantité sur la ... du modèle ?

Exercice 4 (6pts). On considère un échantillon d'apprentissage $\{(x_i, y_i), i = 1, \dots, n\}$ où x_i est dans $\mathbb{R}^p$ et $y_i \in \mathbb{R}$. Soit $\varepsilon > 0$. On considère le problème d'optimisation suivant :

$$\begin{cases} \min_{\beta, \beta_0} \frac{1}{2} \|\beta\|_2^2 & \text{sous les contraintes} \\ y_i - (\langle \beta, x_i \rangle + \beta_0) \leq \varepsilon & \text{et} \quad \langle \beta, x_i \rangle + \beta_0 - y_i \leq \varepsilon \quad \forall i \in \{1, \dots, n\}. \end{cases}$$

1. (1 pt) Quelle interprétation pouvez-vous donner de ce problème d'optimisation ? De quel algorithme de régression vu en cours se rapproche-t-il ? Expliquez votre réponse.
2. (0,5pt) Comment modifier ce problème pour que la contrainte puisse être flexible ?
3. (1 pt) Ecrire le lagrangien $L(\beta, \beta_0, \alpha, \alpha^*)$ associé au problème posé initialement avec $\alpha = (\alpha_i)_{i=1}^n$, $\alpha^* = (\alpha_i^*)_{i=1}^n$ (De préférence, on écrira les deux contraintes sous la forme $\geq$).
4. (1pt) Ecrire les équations de stationnarité associées. En notant $(\beta(\alpha), \beta_0(\alpha))$ une solution du problème, en déduire une expression de $\beta(\alpha)$ en fonction des α_i , α_i^* et x_i .
5. (1pt) En déduire une expression simplifiée de $L(\beta(\alpha), \beta_0(\alpha), \alpha, \alpha^*)$ ainsi que le nouveau problème d'optimisation à résoudre (on n'oubliera pas la contrainte).
6. (1pt) Supposons les α_i , α_i^* calculés. Quelle est l'expression du prédicteur f obtenu en fonction des α_i , α_i^* et β_0 ?
7. (0,5pt) Comment retrouver l'expression de β_0 ?